

Ejercicio: Análisis Predictivo con el Titanic

Objetivo

Construir y evaluar un modelo de clasificación basado en un **Árbol de Decisión (Tree)** para predecir la supervivencia de los pasajeros, integrando el análisis exploratorio (EDA) y la validación de métricas.

Paso 0: Diccionario de Datos (Entendiendo las columnas)

Antes de empezar, revisen qué significa cada columna en su dataset para entender el contexto del problema:

- **PassengerId:** ID único del pasajero.
 - **Survived:** ¿Sobrevivió? (**0** = No, **1** = Sí). *Este es nuestro Target.*
 - **Pclass:** Clase del ticket (**1**, **2** o **3**). Refleja el estatus socioeconómico.
 - **Name:** Nombre y título del pasajero.
 - **Sex:** Género (male/female).
 - **Age:** Edad en años.
 - **SibSp:** Cantidad de hermanos o cónyuges a bordo.
 - **Parch:** Cantidad de padres o hijos a bordo.
 - **Ticket:** Número de ticket.
 - **Fare:** Tarifa pagada por el pasaje.
 - **Cabin:** Número de camarote.
 - **Embarked:** Puerto de embarque (**C** = Cherbourg, **Q** = Queenstown, **S** = Southampton).
-

Paso 1: Conexión y Selección de Variables

Carguen el archivo desde [este enlace](#) utilizando el widget **Datasets** y configuren el widget **Select Columns** de la siguiente manera:

- **Target:** **Survived**.
- **Meta:** Muevan aquí **Name**, **Ticket**, **PassengerId** y **Cabin**. Estas columnas no ayudan al modelo a generalizar y deben quedar fuera del entrenamiento.
- **Edit Domain:** utiliza este widget para cambiar variables categoricas a numericas (EJ: Age)

Paso 2: Exploración Inicial (EDA Visual)

Antes de entrenar al modelo, debemos entender las tendencias de los datos. Conecten los widgets de visualización directamente al paso anterior:

- **Distributions:** Creen un histograma de **Survived** agrupado por **Sex**.
 - *Pregunta:* ¿Se cumple visualmente la regla de "mujeres y niños primero"?
 - **Scatter Plot:** Contrasten **Age** vs **Fare**, usando **Survived** para el color.
 - *Pregunta:* ¿Los pasajeros que pagaron una tarifa más alta tuvieron más chances de sobrevivir?
 - **Box Plot:** Comparen la distribución de **Age** según si sobrevivieron o no.
 - *Pregunta:* ¿Existen valores atípicos (outliers) en la edad de los sobrevivientes?
-

Paso 3: División de Datos (Split)

Para evaluar el modelo correctamente, debemos separar los datos. Utilicen el widget **Data Sampler**:

- Configuren una división de **80% para entrenamiento** (*Data Sample*) y **20% para test** (*Remaining Data*).
-

Paso 4: Construcción del Modelo (Tree)

Conecten el algoritmo de **Árbol de Decisión (Tree)** a la salida de entrenamiento (*Data Sample*).

- *Sugerencia:* Pueden usar el **Tree Viewer** para observar la estructura lógica de las decisiones que toma el modelo.
-

Paso 5: Evaluación (Test and Score)

Conecten el modelo y los datos de prueba (**Remaining Data**) a este widget. Observen la métrica **CA (Classification Accuracy)** o Exactitud.

- *Pregunta:* ¿Cuál es el valor de CA obtenido? ¿Cómo lo interpretarían en términos de "predicciones correctas totales"?
- *Reflexión:* Si el CA es de 0.79, ¿el modelo es "bueno" o depende del contexto?

Paso 6: Análisis de Errores (Matriz de Confusión)

Abran el widget **Confusion Matrix** y analicen los tipos de errores:

- **Falsos Positivos (FP):** El modelo predijo que sobrevivió, pero falleció.
 - **Falsos Negativos (FN):** El modelo predijo que falleció, pero sobrevivió.
 - *Pregunta de reflexión:* En una emergencia, ¿qué error consideran más grave: un FP o un FN? ¿Por qué?
 - *Análisis:* Según su matriz, ¿qué tipo de error cometió más el modelo?
-

Paso 7: Visualización y Predicciones

Usen el widget **Predictions** para ver casos reales frente a la predicción.

- Identifiquen a un pasajero que el modelo **no** haya logrado predecir correctamente.
 - Miren su clase, sexo y edad. ¿Qué creen que pudo haber confundido al árbol en ese caso particular?
-

Entregables:

Deberán presentar un informe breve que incluya:

1. Captura de pantalla del **Workflow** completo.
2. Captura de los gráficos del **EDA** que les haya servido para entender los datos.
3. El valor de **CA** obtenido y captura de la **Matriz de Confusión**.
4. Respuestas a las preguntas de reflexión planteadas en los pasos 2, 5, 6 y 7.